

Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение
высшего образования

«Алтайский государственный технический университет им. И. И. Ползунова»

Факультет информационных технологий Кафедра информатики,
вычислительной техники и информационной безопасности

Отчет защищен с оценкой _____
Преподаватель _____ С. В. Умбетов
« ____ » _____ 2026 г.

Отчёт по лабораторной работе №1 по дисциплине
«Устройство и функционирование интеллектуальных
информационных систем» «Лабораторная работа с
табличными данными в Pandas»

ЛР 09.02.08.23.001

Студент группы	<u>1ИИС-41</u>	<u>М.А.Синтиков</u>
	группа	и.о., фамилия
Преподаватель	<u>старший преподаватель, доцент</u>	<u>С. В. Умбетов</u>
	должность, ученая степень	и.о., фамилия

Барнаул 2026

Лабораторная работа №1

Лабораторная работа с табличными данными в Pandas

Цель работы: Освоить базовые и продвинутые приёмы работы с табличными данными в библиотеке Pandas на примере реального набора данных о пассажирах «Титаника». Научиться загружать, исследовать, фильтровать, агрегировать и преобразовывать табличные данные, а также делать аналитические выводы на основе полученных результатов.

Задачи работы: В ходе выполнения лабораторной работы необходимо:

1. Изучить теоретические основы работы с библиотекой Pandas: объекты Series и DataFrame , их создание и основные свойства.
2. Освоить чтение данных из CSV-файлов с помощью функции `pd.read_csv()` и её параметров.
3. Научиться получать первичную информацию о датафрейме с помощью методов `.head()` , `.tail()` , `.info()` , `.describe()` .
4. Освоить индексацию и доступ к данным через `.loc` , `.iloc` и обращение к столбцам.
5. Научиться фильтровать данные по одному и нескольким условиям с использованием логических операторов.
6. Освоить статистические методы (`.mean()` , `.max()` , `.min()` , `.sum()` , `.std()` , `.count()`) и их применение к датафреймам и отдельным столбцам.
7. Изучить группировку данных с помощью `.groupby()` и агрегацию через `.agg()` .
8. Научиться строить сводные таблицы с помощью `.pivot_table()` .
9. Освоить работу с пропущенными значениями: обнаружение, удаление, заполнение.
10. Научиться создавать новые признаки на основе существующих с использованием арифметических операций, `pd.cut()` и `.apply()` .
11. Провести комплексный аналитический анализ датасета Titanic и сформулировать содержательные выводы.
12. Закрепить полученные навыки ответами на контрольные вопросы.

Задание принято:

Ситников М.А.



Подпись

Ход работы

Задача 1. Загрузка и первичный осмотр данных




Рис.1 – Файл train.csv скачан и добавлен на гугл диск




Рис.2 – Данные train.csv загружены в DataFrame с помощью pd.read_csv()




Рис.3 - Вывод первых 10 строк таблицы с помощью display(titanic.head(10))

```
[3]
0
OK
import pandas as pd

titanic = pd.read_csv('train.csv')
display(titanic.head(10))
display(titanic.tail())
```

	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
0	1	0	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.2500	NaN	S
1	2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	0	PC 17599	71.2833	C85	C
2	3	1	3	Heikkinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.9250	NaN	S
3	4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.1000	C123	S
4	5	0	3	Allen, Mr. William Henry	male	35.0	0	0	373450	8.0500	NaN	S
5	6	0	3	Moran, Mr. James	male	NaN	0	0	330877	8.4583	NaN	Q
6	7	0	1	McCarthy, Mr. Timothy J	male	54.0	0	0	17463	51.8625	E46	S
7	8	0	3	Palsson, Master. Gosta Leonard	male	2.0	3	1	349909	21.0750	NaN	S
8	9	1	3	Johnson, Mrs. Oscar W (Elisabeth Vilhelmina Berg)	female	27.0	0	2	347742	11.1333	NaN	S
9	10	1	2	Nasser, Mrs. Nicholas (Adele Achem)	female	14.0	1	0	237736	30.0708	NaN	C
886	887	0	2	Montvila, Rev. Juozas	male	27.0	0	0	211536	13.00	NaN	S
887	888	1	1	Graham, Miss. Margaret Edith	female	19.0	0	0	112053	30.00	B42	S
888	889	0	3	Johnston, Miss. Catherine Helen "Carrie"	female	NaN	1	2	W./C. 6607	23.45	NaN	S
889	890	1	1	Behr, Mr. Karl Howell	male	26.0	0	0	111369	30.00	C148	C
890	891	0	3	Dooley, Mr. Patrick	male	32.0	0	0	370376	7.75	NaN	Q

Рис.4 - Вывод последних 5 строк с помощью display(titanic.tail())

Задача 2. Получение информации о датафрейме

```
[4]
0
OK
display(titanic.info())
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 891 entries, 0 to 890
Data columns (total 12 columns):
#   Column          Non-Null Count  Dtype
---  ---
0   PassengerId     891 non-null    int64
1   Survived        891 non-null    int64
2   Pclass          891 non-null    int64
3   Name            891 non-null    object
4   Sex             891 non-null    object
5   Age             714 non-null    float64
6   SibSp           891 non-null    int64
7   Parch           891 non-null    int64
8   Ticket          891 non-null    object
9   Fare            891 non-null    float64
10  Cabin           204 non-null    object
11  Embarked        889 non-null    object
dtypes: float64(2), int64(5), object(5)
memory usage: 83.7+ KB
None
```

Рис-5 – Полученная информация о типах данных с помощью .info

Результат: .info() показало, что существует 2 столбца с дробными числами float64 (Age и Fare), 5 столбцов с целыми числами int64 (PassengerId, Survived, Pclass, SibSp и Parch) и 5 столбцов со сточными данными (Name, Sex, Ticket, Cabin, Embarked). Также в нескольких столбцах замечены

пропуски: Age (177 пропусков), Cabin (687 пропусков) и Embarked (2 пропуска)




Рис.6 - .describe() применён к числовым столбцам.

```
2] display(titanic.info())
0 titanic.describe()
cek titanic.describe(include=['object'])

*** <class 'pandas.core.frame.DataFrame'>
RangeIndex: 891 entries, 0 to 890
Data columns (total 12 columns):
#   Column      Non-Null Count  Dtype
---  -
0   PassengerId  891 non-null    int64
1   Survived     891 non-null    int64
2   Pclass       891 non-null    int64
3   Name         891 non-null    object
4   Sex          891 non-null    object
5   Age          714 non-null    float64
6   SibSp        891 non-null    int64
7   Parch        891 non-null    int64
8   Ticket       891 non-null    object
9   Fare         891 non-null    float64
10  Cabin        204 non-null    object
11  Embarked     889 non-null    object
dtypes: float64(2), int64(5), object(5)
memory usage: 83.7+ KB
None
```

	Name	Sex	Ticket	Cabin	Embarked
count	891	891	891	204	889
unique	891	2	681	147	3
top	Dooley, Mr. Patrick	male	347082	G6	S
freq	1	577	7	4	644

Рис.7 - .describe(include=['object']) применён к текстовым столбцам.

Результат: .describe(include=['object']) показал, что на корабле больше всего было мужчин (577 человек), а больше всего людей погрузилось с порта S (Саутгемптон)(644 человека)

Задача 3. Работа с Series

```
embarked_series = titanic['Embarked'].head(5).copy()
embarked_series.index = ['Первый', 'Второй', 'Третий', 'Четвёртый', 'Пятый']
display(embarked_series)
```

Embarked	
Первый	S
Второй	C
Третий	S
Четвёртый	S
Пятый	S

dtype: object

Рис.8 - Embarked преобразован в Series. Установлен произвольный индекс для первых 5 элементов этой Series.

```
[17] 0 сек. embarked = titanic['Embarked'].head(5).copy()
embarked.index = ['Первый', 'Второй', 'Третий', 'Четвёртый', 'Пятый']
display(embarked)
embarked.loc[['Первый', 'Третий', 'Пятый']]
```

Embarked	
Первый	S
Второй	C
Третий	S
Четвёртый	S
Пятый	S

dtype: object

Embarked	
Первый	S
Третий	S
Пятый	S

dtype: object

Рис.9 – Получен доступ к первому, третьему и пятому элементу с помощью .loc

```
[19] 0 сек.
embarked = titanic['Embarked'].head(5).copy()
embarked.index = ['Первый', 'Второй', 'Третий', 'Четвёртый', 'Пятый']
display(embarked)
embarked.loc[['Первый', 'Третий', 'Пятый']]
embarked.iloc[[1, 3]]
```

Embarked	
Первый	S
Второй	C
Третий	S
Четвёртый	S
Пятый	S

dtype: object

Embarked	
Второй	C
Четвёртый	S

dtype: object

Рис.10 - Получен доступ ко второму и четвёртому элементу с помощью `.iloc`

Задача 4. Статистические методы

```
[4] 0 сек.
print('Средний возраст пассажиров:', titanic['Age'].mean())
print('Максимальная стоимость билета:', titanic['Fare'].max())
print('Минимальная стоимость билета:', titanic['Fare'].min())
print('Стандартное отклонение возраста:', titanic['Age'].std())
```

Средний возраст пассажиров: 29.69911764705882
Максимальная стоимость билета: 512.3292
Минимальная стоимость билета: 0.0
Стандартное отклонение возраста: 14.526497332334044

Рис.11 - Вычислен средний возраст пассажиров с помощью `.mean()`. Найдена максимальная и минимальная стоимость билета с помощью `.max()` и `.min()`. Вычислено стандартное отклонение для столбца с возрастом с помощью `.std()`.

Результат:

Средний возраст пассажира ≈ 30 лет

Максимальная стоимость билета = 512.33

Минимальная стоимость билета = 0

Стандартное отклонение возраста ≈ 14.53 лет

[7] 0 сек.

```
titanic[titanic['Age'] > 30]
titanic[titanic['Fare'] > titanic['Fare'].mean()]
titanic[(titanic['Pclass']==1) & (titanic['Sex']=='female')]
```

PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
1	2	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	0	PC 17599	71.2833	C85	C
3	4	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.1000	C123	S
11	12	1	Bonnell, Miss. Elizabeth	female	58.0	0	0	113783	26.5500	C103	S
31	32	1	Spencer, Mrs. William Augustus (Marie Eugenie)	female	NaN	1	0	PC 17569	146.5208	B78	C
52	53	1	Harper, Mrs. Henry Sleeper (Myna Haxtun)	female	49.0	1	0	PC 17572	76.7292	D33	C
...	...	...	...	...	...	...	...	...	...	...	...
856	857	1	Wick, Mrs. George Dennick (Mary Hitchcock)	female	45.0	1	1	36928	164.8667	NaN	S
862	863	1	Swift, Mrs. Frederick Joel (Margaret Welles Ba...	female	48.0	0	0	17466	25.9292	D17	S
871	872	1	Beckwith, Mrs. Richard Leonard (Sallie Monypeny)	female	47.0	1	1	11751	52.5542	D35	S
879	880	1	Potter, Mrs. Thomas Jr (Lily Alexenia Wilson)	female	56.0	0	1	11767	83.1583	C50	C
887	888	1	Graham, Miss. Margaret Edith	female	19.0	0	0	112053	30.0000	B42	S

94 rows x 12 columns

Рис.14 – Пассажиры женского пола из первого класса отфильтрованы с помощью `titanic[(titanic['Pclass'] == 1) & (titanic['Sex'] == 'female')]`.

Результат: Женщин в первом классе: 94 человека

[10] 0 сек.

```
titanic[titanic['Age'] > 30]
titanic[titanic['Fare'] > titanic['Fare'].mean()]
titanic[(titanic['Pclass']==1) & (titanic['Sex']=='female')]
titanic[(titanic['Pclass']==1) & (titanic['Sex']=='female')]['Age'].mean()
```

... np.float64(34.61176470588235)

Рис.15 –Вычислен средний возраст женщины из первого класса с помощью `titanic[(titanic['Pclass'] == 1) & (titanic['Sex'] == 'female')]['Age'].mean()` .

Результат: Средний возраст женщины из первого класса ≈ 35 лет

Задача 6. Комбинированная фильтрация и статистика

```
survived = titanic[(titanic['Survived'] == 1) & (titanic['Age'] < 18)]
display(survived)
```

PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
9	1	2	Nasser, Mrs. Nicholas (Adele Achem)	female	14.00	1	0	237736	30.0708	NaN	C
10	1	3	Sandstrom, Miss. Marguerite Rut	female	4.00	1	1	PP 9549	16.7000	G6	S
22	1	3	McGowan, Miss. Anna "Annie"	female	15.00	0	0	330923	8.0292	NaN	Q
39	1	3	Nicola-Yarred, Miss. Jamila	female	14.00	1	0	2651	11.2417	NaN	C
43	1	2	Laroche, Miss. Simonne Marie Anne Andree	female	3.00	1	2	SC/Paris 2123	41.5792	NaN	C
...	...	...	...	...	...	...	...	...	...	...	...
830	1	3	Yasbeck, Mrs. Antoni (Selini Alexander)	female	15.00	1	0	2659	14.4542	NaN	C
831	1	2	Richards, Master. George Sibley	male	0.83	1	1	29106	18.7500	NaN	S
853	1	1	Lines, Miss. Mary Conover	female	16.00	0	1	PC 17592	39.4000	D28	S
869	1	3	Johnson, Master. Harold Theodor	male	4.00	1	1	347742	11.1333	NaN	S
875	1	3	Najib, Miss. Adele Kiamie "Jane"	female	15.00	0	0	2667	7.2250	NaN	C

61 rows x 12 columns

Рис.16 – Найдены все пассажиры, которые выжили и возрастом менее 18 лет с помощью `titanic[(titanic['Survived'] == 1) & (titanic['Age'] < 18)]`

```
survived = titanic[(titanic['Survived'] == 1) & (titanic['Age'] < 18)]
display(survived)
print('Средняя стоимость билета выживших пассажиров:', survived['Fare'].mean())
print('Количество выживших пассажиров:', survived['PassengerId'].count())
```

PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
9	1	2	Nasser, Mrs. Nicholas (Adele Achem)	female	14.00	1	0	237736	30.0708	NaN	C
10	1	3	Sandstrom, Miss. Marguerite Rut	female	4.00	1	1	PP 9549	16.7000	G6	S
22	1	3	McGowan, Miss. Anna "Annie"	female	15.00	0	0	330923	8.0292	NaN	Q
39	1	3	Nicola-Yarred, Miss. Jamila	female	14.00	1	0	2651	11.2417	NaN	C
43	1	2	Laroche, Miss. Simonne Marie Anne Andree	female	3.00	1	2	SC/Paris 2123	41.5792	NaN	C
...	...	...	...	...	...	...	...	...	...	...	...
830	1	3	Yasbeck, Mrs. Antoni (Selini Alexander)	female	15.00	1	0	2659	14.4542	NaN	C
831	1	2	Richards, Master. George Sibley	male	0.83	1	1	29106	18.7500	NaN	S
853	1	1	Lines, Miss. Mary Conover	female	16.00	0	1	PC 17592	39.4000	D28	S
869	1	3	Johnson, Master. Harold Theodor	male	4.00	1	1	347742	11.1333	NaN	S
875	1	3	Najib, Miss. Adele Kiamie "Jane"	female	15.00	0	0	2667	7.2250	NaN	C

61 rows x 12 columns

Средняя стоимость билета выживших пассажиров: 34.857309836065575
Количество выживших пассажиров: 61


Рис.17 – Вычислена средняя стоимость билета и количество выживших пассажиров с помощью `survived['Fare'].mean()` и `survived['PassengerId'].count()`

Результат:

Средняя стоимость билета выживших пассажиров ≈ 34.86

Количество выживших пассажиров = 61 человек

Задача 7. Группировка данных



```
[47] titanic.groupby('Pclass')['Age'].mean()
```

Age	
Pclass	
1	38.233441
2	29.877630
3	25.140620

dtype: float64


Рис.18 – Вычислен средний возраст пассажиров для каждого из трёх классов с помощью `titanic.groupby('Pclass')['Age'].mean()`

Результат:

Средний возраст в первом классе ≈ 38 лет

Средний возраст во втором классе ≈ 30 лет

Средний возраст в третьем классе ≈ 25 лет



```
[48] titanic.groupby('Pclass')['Age'].mean()
titanic.groupby('Pclass')['Fare'].agg(['count', 'mean'])
```

	count	mean
Pclass		
1	216	84.154687
2	184	20.662183
3	491	13.675550

Рис.19 – Вычислена средняя стоимость билета и количество пассажиров для каждого из трёх классов с помощью `titanic.groupby('Pclass')['Fare'].agg(['count', 'mean'])`

Результат:

Средняя цена билета в первом классе ≈ 84.15 Количество пассажиров = 216

Средняя цена билета во втором классе ≈ 20.66 Количество пассажиров = 184

Средняя цена билета в третьем классе ≈ 13.68 Количество пассажиров = 491

```
[54]
0
сек.
▶ titanic.groupby('Pclass')['Age'].mean()
  titanic.groupby('Pclass')['Fare'].agg(['count', 'mean'])
  titanic.groupby('Pclass')['Fare'].agg(['count', 'mean']).sort_values('mean', ascending=False)
```

	count	mean
Pclass		
1	216	84.154687
2	184	20.662183
3	491	13.675550

Рис.20 – Результат отсортирован по средней стоимости билета в порядке убывания с помощью `titanic.groupby('Pclass')['Fare'].agg(['count', 'mean']).sort_values('mean', ascending=False)`

Задача 8. Сводная таблица


```
[55]
0
сек.
▶ titanic.pivot_table(values='Survived', index='Pclass', columns='Sex', aggfunc='mean')
```

	Sex	female	male
Pclass			
1		0.968085	0.368852
2		0.921053	0.157407
3		0.500000	0.135447

Рис.21 - Создана сводная таблица с помощью `.pivot_table()`, где: значения — доля выживших (Survived); строки — классы билета (Pclass); столбцы — пол (Sex).

Результат: Выше всего доля выживших у женщин первого класса ($\approx 97\%$), ниже всего у мужчин третьего класса ($\approx 14\%$).

Задача 9. Работа с пропущенными значениями



```
[59] 0 OK
titanic.isnull().sum()
***
PassengerId  0
Survived     0
Pclass       0
Name         0
Sex          0
Age         177
SibSp        0
Parch        0
Ticket       0
Fare         0
Cabin       687
Embarked     2
dtype: int64
```

Рис.22 – Выведено количество пропусков с помощью `titanic.isnull().sum()`

Результат: В столбце Age пропущено 177 значений, в Cabin пропущено 687 значений, в Embarked пропущено 2 значения.

```
[56] 0 ✓ titanic.isnull().sum()
      0 ✓ titanic.isnull().sum() / len(titanic) * 100
```

	0
PassengerId	0.000000
Survived	0.000000
Pclass	0.000000
Name	0.000000
Sex	0.000000
Age	19.865320
SibSp	0.000000
Parch	0.000000
Ticket	0.000000
Fare	0.000000
Cabin	77.104377
Embarked	0.224467

dtype: float64

Рис.23 – Выведен процент пропусков с помощью `titanic.isnull().sum() / len(titanic) * 100`

Результат: Процент пропущенных данных в Age $\approx 19.87\%$, в Cabin $\approx 77.1\%$, в Embarked $\approx 0.22\%$

```
[64] 0 ✓ titanic.isnull().sum()
      0 ✓ titanic.isnull().sum() / len(titanic) * 100
      0 ✓ titanic['Embarked'] = titanic['Embarked'].fillna('S')
      0 ✓ titanic['Age'] = titanic['Age'].fillna(titanic['Age'].mean())
```

Рис.24 – Пропуски в столбце Embarked заполнены значением S с помощью `titanic['Embarked'] = titanic['Embarked'].fillna('S')`. Пропуски в столбце Age заполнены медианой с помощью `titanic['Age'] = titanic['Age'].fillna(titanic['Age'].mean())`.

```
[65] 0 ✓ titanic.isnull().sum()
      0 ✓ titanic.isnull().sum() / len(titanic) * 100
      0 ✓ titanic['Embarked'] = titanic['Embarked'].fillna('S')
      0 ✓ titanic['Age'] = titanic['Age'].fillna(titanic['Age'].mean())
      0 ✓ titanic.duplicated(subset=['PassengerId']).sum()
      0 ✓ np.int64(0)
```

Рис.25 – Проверка на наличие дубликатов с помощью `titanic.duplicated(subset=['PassengerId']).sum()`

Результат: Дубликаты не найдены (`np.int64(0)`)

```
[66] 0 ✓ titanic.isnull().sum()
      0 ✓ titanic.isnull().sum() / len(titanic) * 100
      0 ✓ titanic['Embarked'] = titanic['Embarked'].fillna('S')
      0 ✓ titanic['Age'] = titanic['Age'].fillna(titanic['Age'].mean())
      0 ✓ titanic.duplicated(subset=['PassengerId']).sum()
      0 ✓ titanic.drop_duplicates(subset=['PassengerId'], keep='first')
```

PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked	
0	1	0	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.2500	NaN	S
1	2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	0	PC 17599	71.2833	C85	C
2	3	1	3	Heikinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.9250	NaN	S
3	4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.1000	C123	S
4	5	0	3	Allen, Mr. William Henry	male	35.0	0	0	373450	8.0500	NaN	S
...	...	...	...	...	...	...	...	...	...	...	...	...
886	887	0	2	Montvila, Rev. Juozas	male	27.0	0	0	211536	13.0000	NaN	S
887	888	1	1	Graham, Miss. Margaret Edith	female	19.0	0	0	112053	30.0000	B42	S
888	889	0	3	Johnston, Miss. Catherine Helen "Carrie"	female	28.0	1	2	W./C. 6607	23.4500	NaN	S
889	890	1	1	Behr, Mr. Karl Howell	male	26.0	0	0	111369	30.0000	C148	C
890	891	0	3	Dooley, Mr. Patrick	male	32.0	0	0	370376	7.7500	NaN	Q

891 rows x 12 columns

Рис.26 – Устранение дубликатов с помощью `titanic.drop_duplicates(subset=['PassengerId'], keep='first')`

Задача 10. Создание новых признаков и расширенный анализ

```
[68] 0 ✓ titanic['FamilySize'] = titanic['SibSp'] + titanic['Parch'] + 1
```

Рис.27 – Создан новый признак `FamilySize`, который равен `SibSp+Parch+1` с помощью `titanic['FamilySize'] = titanic['SibSp'] + titanic['Parch'] + 1`

```
[69] 0 ✓ titanic['FamilySize'] = titanic['SibSp'] + titanic['Parch'] + 1
      0 ✓ titanic['IsAlone'] = titanic['FamilySize'].apply(lambda x: 1 if x == 1 else 0)
```

Рис.28 – Создан признак IsAlone, который равен 1 если FamilySize равен 1. В другом случае (если FamilySize >1) IsAlone равно 0.

```
[16] 0 сек.
titanic['FamilySize'] = titanic['SibSp'] + titanic['Parch'] + 1
titanic['IsAlone'] = titanic['FamilySize'].apply(lambda x: 1 if x == 1 else 0)
titanic['AgeGroup'] = pd.cut(titanic['Age'], bins=[0, 12, 18, 35, 60, 100], labels=['ребёнок', 'подросток', 'молодой', 'взрослый', 'пожилой'])
```

Рис.29 – Создан признак AgeGroup с помощью pd.cut() (группы: ребёнок 0–12, подросток 13–18, молодой 19–35, взрослый 36–60, пожилой 60+).

```
[20] 0 сек.
titanic['FamilySize'] = titanic['SibSp'] + titanic['Parch'] + 1
titanic['IsAlone'] = titanic['FamilySize'].apply(lambda x: 1 if x == 1 else 0)
titanic['AgeGroup'] = pd.cut(titanic['Age'], bins=[0, 12, 18, 35, 60, 100], labels=['ребёнок', 'подросток', 'молодой', 'взрослый', 'пожилой'])
titanic.groupby('AgeGroup', observed=True)['Survived'].mean()

***
Survived
AgeGroup
ребёнок    0.579710
подросток  0.428571
молодой    0.382682
взрослый   0.400000
пожилой    0.227273
dtype: float64
```

Рис.30 – Вычислена доля выживших с помощью titanic.groupby('AgeGroup', observed=True)['Survived'].mean()

Результат:

Самая большая доля выживших у детей ($\approx 58\%$), а самая маленькая у стариков ($\approx 23\%$)

```
[21] 0 сек.
titanic['FamilySize'] = titanic['SibSp'] + titanic['Parch'] + 1
titanic['IsAlone'] = titanic['FamilySize'].apply(lambda x: 1 if x == 1 else 0)
titanic['AgeGroup'] = pd.cut(titanic['Age'], bins=[0, 12, 18, 35, 60, 100], labels=['ребёнок', 'подросток', 'молодой', 'взрослый', 'пожилой'])
titanic.groupby('AgeGroup', observed=True)['Survived'].mean()
titanic.groupby('AgeGroup', observed=True)['Fare'].mean()

***
Fare
AgeGroup
ребёнок    31.536352
подросток  33.451313
молодой    29.925929
взрослый   44.259658
пожилой    41.371214
dtype: float64
```

Рис.31 – Вычислена средняя стоимость билета с помощью titanic.groupby('AgeGroup', observed=True)['Fare'].mean()

Самая большая средняя стоимость билетов у взрослых (≈ 44.25), а самая маленькая у детей (≈ 31.53)

```
[22]
0 сек.
titanic['FamilySize'] = titanic['SibSp'] + titanic['Parch'] + 1
titanic['IsAlone'] = titanic['FamilySize'].apply(lambda x: 1 if x == 1 else 0)
titanic['AgeGroup'] = pd.cut(titanic['Age'], bins=[0, 12, 18, 35, 60, 100], labels=['ребёнок', 'подросток', 'молодой', 'взрослый', 'пожилой'])
titanic.groupby('AgeGroup', observed=True)['Survived'].mean()
titanic.groupby('AgeGroup', observed=True)['Fare'].mean()
titanic.groupby('AgeGroup', observed=True)['PassengerId'].count()
```

AgeGroup	PassengerId
ребёнок	69
подросток	70
молодой	358
взрослый	195
пожилой	22

dtype: int64

Рис.32 – Вычислено количество пассажиров с помощью `titanic.groupby('AgeGroup', observed=True)['PassengerId'].count()`

Самая распространённая возрастная группа пассажиров – это молодые (358), а самая редкая – старики (22)

```
[23]
0 сек.
titanic['FamilySize'] = titanic['SibSp'] + titanic['Parch'] + 1
titanic['IsAlone'] = titanic['FamilySize'].apply(lambda x: 1 if x == 1 else 0)
titanic['AgeGroup'] = pd.cut(titanic['Age'], bins=[0, 12, 18, 35, 60, 100], labels=['ребёнок', 'подросток', 'молодой', 'взрослый', 'пожилой'])
titanic.groupby('AgeGroup', observed=True)['Survived'].mean()
titanic.groupby('AgeGroup', observed=True)['Fare'].mean()
titanic.groupby('AgeGroup', observed=True)['PassengerId'].count()
titanic.pivot_table(values='Survived', index='AgeGroup', columns='Sex', aggfunc='mean', observed=True)
```

AgeGroup	female	male
ребёнок	0.593750	0.567568
подросток	0.750000	0.088235
молодой	0.783333	0.180672
взрослый	0.771429	0.192000
пожилой	1.000000	0.105263

Рис.33 – Построена сводная таблица по возрастным группам с помощью `titanic.pivot_table(values='Survived', index='AgeGroup', columns='Sex', aggfunc='mean', observed=True)`

Результат: Все пожилые женщины выжили (100%), самая низкая доля выживших у подростков мужского пола ($\approx 9\%$).

Задача 11. Комплексный аналитический отчёт

```
[73]
0 сек.
titanic['Embarked'].value_counts().head(3)
```

Embarked	count
S	646
C	168
Q	77

dtype: int64

Рис.34 – Определены три порта посадки по количеству пассажиров с помощью `titanic['Embarked'].value_counts().head(3)`

Результат: больше всего людей погрузилось с порта S(Саутгемптон), меньше всего с порта Q(Куинстаун)




Рис.35 – Для каждого порта вычислен средний возраст пассажиров

Результат:

Средний возраст в порту C(Шербур) ≈ 31 год

Средний возраст в порту Q(Куинстаун) ≈ 28 год

Средний возраст в порту S(Саутгемптон) ≈ 29 год




Рис.36 – Для каждого порта вычислена стоимость билета

Результат:

Самые дорогие билеты были в порту C(Шербур) ≈ 60

Самые дешёвые билеты были в порту Q(Куинстаун) ≈ 13.2




Рис.37 – Для каждого порта вычислена доля выживших пассажиров

Результат: Наибольшее количество выживших из порта С(Шербур) ($\approx 55\%$), меньше всего выжило пассажиров с порта S(Саутгемптон)($\approx 33\%$)




Рис.38 – Для каждого порта вычислена доля пассажиров из первого класса

Результат: Больше всего выжило пассажиров первого класса из порта С(Шербур) ($\approx 51\%$), меньше всего из порта Q(Куинстаун) ($\approx 3\%$)

В результате я выяснил, что порт С(Шербур) связан с наибольшей долей выживших ($\approx 55\%$), так как большая часть пассажиров была из первого класса ($\approx 51\%$) и они, скорее всего, имели приоритет при эвакуации с корабля.

Задача 12. Сравнительный анализ по размеру семьи




Рис.39 – Данные FamilySize отсортированы по доле выживших

Результат: Чаще всего выживали семьи из 4-х человек ($\approx 72\%$). Семьи с числом пассажиров 8 и больше человек не выживали.





Рис.40 – Данные FamilySize отсортированы по среднему возрасту

Результат: Самый большой возраст в среднем был у одиночек (≈ 32 года). Самый маленький был в семьях с 7 пассажирами (≈ 15 лет)



```
titanic.groupby('FamilySize')['Survived'].mean()
titanic.groupby('FamilySize')['Age'].mean()
titanic.groupby('FamilySize')['Fare'].mean()
```

FamilySize	Fare
1	21.242689
2	49.894129
3	39.692482
4	54.864510
5	58.094453
6	73.722727
7	29.366667
8	46.900000
11	69.550000

dtype: float64

Рис.41 – Данные FamilySize отсортированы по средней стоимости билета

Результат: Самые дорогие билеты в среднем были у семей с 6 пассажирами (≈ 74), самые дешёвые были у одиночек (≈ 21)

```
[46]
0 сек.
▶ titanic.groupby('FamilySize')['Survived'].mean()
  titanic.groupby('FamilySize')['Age'].mean()
  titanic.groupby('FamilySize')['Fare'].mean()
  titanic.groupby('FamilySize')['PassengerId'].count()
```

PassengerId	
FamilySize	
1	537
2	161
3	102
4	29
5	15
6	22
7	12
8	6
11	7

dtype: int64

Рис.42 – Данные FamilySize отсортированы по количеству пассажиров

Результат: Больше всего на борту было одиночек (537), меньше всего было семей с 8 пассажирами (6)

```
[48]
0 сек.
▶ titanic.groupby('FamilySize')['Survived'].mean()
  titanic.groupby('FamilySize')['Age'].mean()
  titanic.groupby('FamilySize')['Fare'].mean()
  titanic.groupby('FamilySize')['PassengerId'].count()
  big_families = titanic[titanic['FamilySize'] > 10]
  display(big_families[['FamilySize', 'Survived']])
```

	FamilySize	Survived
159	11	0
180	11	0
201	11	0
324	11	0
792	11	0
846	11	0
863	11	0

Рис.43 – Семьи, в которых пассажиров больше 10 отфильтрованы командой `big_families = titanic[titanic['FamilySize'] > 10]`

Результат: Ни одна семья с количеством пассажиров > 10 не выжила

```
[49] 0 OK. titanic.groupby('FamilySize')['Survived'].mean()
titanic.groupby('FamilySize')['Age'].mean()
titanic.groupby('FamilySize')['Fare'].mean()
titanic.groupby('FamilySize')['PassengerId'].count()
big_families = titanic[titanic['FamilySize'] > 10]
display(big_families[['FamilySize', 'Survived']])
family_stats = titanic.groupby('FamilySize')['Survived'].agg('mean').sort_values(ascending=False)
display(family_stats)
```

FamilySize	Survived
159	11
180	11
201	11
324	11
792	11
846	11
863	11

Survived

FamilySize	Survived
4	0.724138
3	0.578431
2	0.552795
7	0.333333
1	0.303538
5	0.200000
6	0.136364
8	0.000000
11	0.000000

Рис.44 – Данные отсортированы по доле выживших




Рис.45 – Сравнение доли выживших среди разных семей(одиночки, маленькие и большие)

Результат: Максимальная доля выживших у маленьких семей ($\approx 58\%$).
Меньше всего выжило больших семей ($\approx 16\%$)

Ссылка на GitHub:

https://github.com/Enot2130/Sitnikov_1iis41/tree/main/Устройство%20и%20функционирование%20интеллектуальных%20информационных%20систем/Лабораторная%20работа%20с%20табличными%20данными%20в%20Pandas

Ссылка на Google Colab:

<https://colab.research.google.com/drive/1ZtHcKNx0iiOZWGZqaxucAnGe9ZKxdMSB?usp=sharing>

Контрольные вопросы

1. Что такое Pandas и для каких задач используется эта библиотека?

Pandas — библиотека Python для работы с табличными данными.

Используется для загрузки, фильтрации, агрегации, преобразования данных и анализа.

2. Чем Series отличается от обычного списка Python? Как создать Series с пользовательским индексом?

Series — одномерный массив с индексами, которые могут быть любыми метками, а в списке — только порядковые номера. Создание: `pd.Series(data, index=['a', 'b', 'c'])`.

3. В чём разница между `.loc` и `.iloc` при доступе к элементам Series?

`.loc` — доступ по меткам индекса (`data.loc['a']`). `.iloc` — по порядковым номерам (`data.iloc[0]`).

4. Как создать DataFrame из словаря? Как задать названия колонок и индекс вручную?

Из словаря: `pd.DataFrame({'col1': [1, 2], 'col2': [3, 4]})`. Вручную: `pd.DataFrame([[1, 2], [3, 4]], columns=['foo', 'bar', 'baz'], index=['foobar', 'foobaz'])`.

5. Какие параметры функции `pd.read_csv()` вы знаете? Для чего используется параметр `usecols`?

`sep` — разделитель данных, по умолчанию `' '`;

`decimal` — разделитель числа на целую и дробную часть, по умолчанию `'.'`;

`names` — список с названиями колонок, не обязательный параметр;

`skiprows` — если файл содержит системную информацию, можно просто её пропустить. Не обязательный параметр;

`usecols` — позволяет загрузить только определённые столбцы, что ускоряет чтение и экономит память;

`index_col` — устанавливает столбец в качестве индекса;

`parse_dates` — автоматически преобразует столбцы с датами в формат `datetime`.

6. Какую информацию выводит метод `.info()`? Какие параметры можно ему передать?

`.info()` выводит индекс, количество и названия колонок, непустые значения, типы данных и память. Параметры:

`verbose`: печатать ли информацию о DataFrame полностью;

`memory_usage`: печатать ли потребление памяти (`True / False / 'deep'`);

`null_counts`: подсчитывать ли количество пустых элементов (по умолчанию `True`).

7. Что показывает метод .describe() для числовых данных и для текстовых данных?

Метод describe показывает основные статистические характеристики данных. Для числовых: число непустых значений (count), среднее (mean), стандартное отклонение (std), минимум и максимум (min и max), 25% и 75% квартили и медиана (50%). Для текстовых (include=['object']): выводится количество непустых строк, уникальных значений, самое частое значение (top) и частота этого значения (freq).

8. Как получить доступ к отдельному столбцу DataFrame? Какие два способа существуют?

Два способа: df['column_name'] или df.column_name.

9. Как отфильтровать DataFrame по одному условию? Как комбинировать несколько условий?

Одно условие: df[df['Age'] > 30]. Несколько: через & (И) и | (ИЛИ), условия в скобках: df[(df['Age'] > 30) & (df['Pclass'] == 1)].

10. Какие статистические методы можно применять к DataFrame и Series? Что произойдет, если применить .mean() ко всему DataFrame с текстовыми столбцами?

.max() - максимум, .min()-минимум, .mean()-среднее значение, .sum()-сумма, .count()-количество не пустых строк, .std()-среднее отклонение. Если применить .mean() ко всему DataFrame с текстом, текстовые столбцы игнорируются (или вызовут ошибку без numeric_only=True).

11. Для чего используется метод .groupby()? Как применить несколько агрегирующих функций одновременно?

.groupby() группирует данные по столбцу для агрегации. Несколько функций: .agg(['mean', 'max', 'count']).

12. Чем сводная таблица (pivot_table) отличается от обычной группировки? В каких случаях удобнее использовать каждую из них?

pivot_table — это группировка с представлением результата в виде таблицы. Удобнее, когда нужно сравнить значения по двум признакам сразу. Обычная группировка проще для одной оси.

13. Как обнаружить и обработать пропущенные значения в DataFrame? Какие стратегии заполнения пропусков вы знаете?

Обнаружение: df.isnull().sum(). Удаление: dropna(). Заполнение: fillna(значение) — средним, медианой, модой или константой.

14. Как создать новый признак на основе существующих? Для чего используется метод pd.cut()?

Новый признак: `df['FamilySize'] = df['SibSp'] + df['Parch'] + 1`. `pd.cut()` — категоризация числовых данных по интервалам: `pd.cut(df['Age'], bins=[0, 12, 18, 60, 100], labels=['ребёнок', 'подросток', 'взрослый', 'пожилой'])`.

15. Как отсортировать DataFrame по значениям одного или нескольких столбцов? Как вывести только топ-N строк?

Сортировка: `df.sort_values('Age')` или по нескольким: `df.sort_values(['Pclass', 'Age'])`. Топ-N: `df.sort_values('Fare', ascending=False).head(N)`.

Вывод

В ходе лабораторной работы я познакомился с библиотекой Pandas и освоил базовые приёмы работы с табличными данными на примере датасета о пассажирах Титаника. Начал с загрузки данных через `pd.read_csv()` и первичного осмотра таблицы — это помогло понять структуру DataFrame, типы данных и наличие пропусков.

При выполнении заданий я отработал создание Series и DataFrame, доступ к элементам через `.loc` и `.iloc`, фильтрацию по одному и нескольким условиям, статистические методы, группировку через `.groupby()` и `.agg()`, построение сводных таблиц через `.pivot_table()`, а также работу с пропусками и создание новых признаков с помощью `pd.cut()` и `.apply()`.

Таким образом, лабораторная работа позволила освоить ключевые инструменты Pandas для загрузки, исследования, фильтрации и агрегации данных, а также научиться делать аналитические выводы на основе статистики.