Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Алтайский государственный технический университет им. И.И. Ползунова»
Университетский технологический колледж
Кафедра Информационные системы в экономике

Отчет защищен с оценкой _____
Преподаватель _____С.В.Умбетов
« » _____ 2026 г.

Отчет по лабораторной работе №4
по дисциплине «Устройство и функционирование интеллектуальных информационных систем»«Статистическая генерация текста на основе марковских цепей»

ЛР 09.02.08.23.004

Студент группы 1ИИС-41 М.А. Ситников
группа фи.о., фамилия
Преподаватель старший преподаватель, доцент С.В. Умбетов
должность, ученая степень фи.о., фамилия

Барнаул 2026

Лабораторная работа №4

Статистическая генерация текста на основе марковских цепей

Цель работы: изучить принципы статистической генерации текста на основе марковских цепей, освоить практическую работу с библиотекой markovify в среде Python (Google Colab) и оценить влияние параметра связности (state_size) на качество, грамматическую правильность и оригинальность генерируемого текста.

Задачи к работе:

1. Сгенерировать по 10 фраз для моделей первого и второго порядка и оценить их на грамматическую правильность и оригинальность.
2. Заменить исходный текст своим (от 50 строк), запустить make_sentence() без параметров и объяснить причины возврата None, а также роль параметра tries.
3. Обучить две модели на разных текстах, объединить их через markovify.combine с весами [0.5, 0.5] и показать примеры смешанного текста.

Задание принято:
Ситников М.А.



Подпись

Ход работы

Задание 1. Оценка влияния параметра связности (state_size)

1. Допишите код, который генерирует 10 предложений для модели со state_size=1 и 10 предложений для модели со state_size=2.

```
[2]
3
сек.
!pip install markovify

Requirement already satisfied: markovify in /usr/local/lib/python3.13/dist-packages (0.9.4)
Requirement already satisfied: unidecode in /usr/local/lib/python3.13/dist-packages (from markovify) (1.4.0)
```

Рис.1 – Скачивание и развертывание внешней библиотеки markovify

```
[3]
0
сек.
import markovify
import random

corpus = """Вчера я приехал в Пятигорск, нанял квартиру на краю города, на самом высоком месте, у подошвы Машука. Во время грозы облака будут спускаться до моей кро
Нынче в пять часов утра, когда я открыл окно, моя комната наполнилась запахом цветов, растущих в скромном палисаднике.
Ветки цветущих черешен смотрят мне в окна, и ветер иногда усыпает мой письменный стол их белыми лепестками.
Вид с трех сторон у меня чудесный. На запад пятиглавый Бешту синеет, как последняя туча умирающей бури.
На север подымается Машук, как мохнатая персидская шапка, и закрывает всю эту часть небосклона.
На восток смотреть мне веселее: внизу передо мною пестреет чистенький, новенький городок, шумят целебные ключи, шумит разноязычная толпа.
А там, дальше, амфитеатром громоздятся горы все синее и туманнее, а на краю горизонта тянется серебряная цепь снеговых вершин, начинаясь Казбеком и кончаясь двугла
Весело жить в такой земле! Какое-то отрадное чувство разлито во всех моих жилах. Воздух чист и свеж, как поцелуй ребенка, солнце светит ярко, небо синее – чего бы,

print("Размер исходного корпуса:", len(corpus), "символов.")

model_order_1 = markovify.Text(corpus, state_size=1)
model_order_2 = markovify.Text(corpus, state_size=2)

print("\n— ГЕНЕРАЦИЯ: МОДЕЛЬ ПЕРВОГО ПОРЯДКА (state_size=1) —")
for i in range(10):
    sentence = model_order_1.make_sentence(tries=100)
    print(f"Фраза {i+1}: {sentence}")

print("\n— ГЕНЕРАЦИЯ: МОДЕЛЬ ВТОРОГО ПОРЯДКА (state_size=2) —")
for i in range(10):
    sentence = model_order_2.make_sentence(tries=100)
    print(f"Фраза {i+1}: {sentence}")

Размер исходного корпуса: 1120 символов.

— ГЕНЕРАЦИЯ: МОДЕЛЬ ПЕРВОГО ПОРЯДКА (state_size=1) —
Фраза 1: Вчера я приехал в Пятигорск, нанял квартиру на самом высоком месте, у подошвы Машука.
Фраза 2: Вчера я приехал в Пятигорск, нанял квартиру на самом высоком месте, у подошвы Машука.
Фраза 3: Ветки цветущих черешен смотрят мне в Пятигорск, нанял квартиру на самом высоком месте, у меня чудесный.
Фраза 4: Вчера я приехал в Пятигорск, нанял квартиру на самом высоком месте, у подошвы Машука.
Фраза 5: На запад пятиглавый Бешту синеет, как поцелуй ребенка, солнце светит ярко, небо синее – чего бы, кажется, больше?
Фраза 6: Вид с трех сторон у подошвы Машука.
Фраза 7: Воздух чист и свеж, как последняя туча умирающей бури.
Фраза 8: Вчера я приехал в окна, и свеж, как последняя туча умирающей бури.
Фраза 9: Ветки цветущих черешен смотрят мне в окна, и свеж, как последняя туча умирающей бури.
Фраза 10: Ветки цветущих черешен смотрят мне в Пятигорск, нанял квартиру на самом высоком месте, у меня чудесный.

— ГЕНЕРАЦИЯ: МОДЕЛЬ ВТОРОГО ПОРЯДКА (state_size=2) —
Фраза 1: None
Фраза 2: None
Фраза 3: None
Фраза 4: None
Фраза 5: None
Фраза 6: None
Фраза 7: None
Фраза 8: None
Фраза 9: None
Фраза 10: None
```

Рис. 2 – Вывод размера исходного корпуса и обучение двух моделей.

Функция выводит длину текста в символах (1120). Затем создаются две марковские модели: model_order_1 с параметром state_size=1 и model_order_2 с параметром state_size=2).

2. Оцените сгенерированный текст по двум критериям: грамматическая правильность на русском языке и оригинальность (не является ли фраза точной копией из исходного текста). Зафиксируйте результаты в отчете.

Результат:

По результатам работы кода объем корпуса – 1120 символов

1. Модель первого порядка (state_size=1)

Грамматическая правильность: Высокая. Все предложения построены грамматически верно, с соблюдением падежных согласований и знаков препинания.

Оригинальность: Низкая. Модель работает как «цитатник»: она практически дословно воспроизводит исходные предложения из текста либо

выдает их обрывки. Это связано с тем, что при контексте в одно слово (state_size=1) граф переходов не имеет выбора, и модель не может генерировать новые комбинации, не отклоняясь от оригинала.

2. Модель второго порядка (state_size=2)
Грамматическая правильность: Модель не выдала текста.
Оригинальность: Не оценивается.
Анализ результата None: Все 10 попыток генерации вернули None. Для данного корпуса (1120 символов) контекст из двух слов (state_size=2) оказался слишком большим. Из-за малого объема текста граф переходов получился сильно разреженным – в нем почти нет повторяющихся пар слов. В результате алгоритм за 100 попыток (tries=100) не смог построить цепочку, которая не была бы точной копией оригинала или не упиралась бы в тупик.

Задание 2. Интеграция кастомного корпуса и обработка исключений
1. Замените демонстрационный текст corpus на массив данных объемом от 50 строк (например, скопируйте статью, главу книги или стихи).

```
corpus_custom = """Утро было свежее и ясное. Я вышел на воздух, чтобы освежиться.
Солнце только что показалось из-за снеговых вершин, и первый луч его упал на холодную скалу.
В ущельях еще клубился туман, тяжелый и сырой.
Дорога шла в гору, извиваясь между кустарниками и каменьями.
Лошади наши устали, и мы принуждены были остановиться у ручья.
Я взошел на высокий утес и посмотрел вниз.
Там, в глубокой пропасти, шумел поток, разбиваясь о камни.
Голова моя кружилась от этой высоты и от чистого горного воздуха.
Кое-где на склонах гор виднелись аулы, прилепившиеся как ласточкины гнезда.
Ветер доносил до меня запах трав и дым от пастушьих костров.
Вдали тянулась цепь снежных гор, ослепительно блестевших на солнце.
Какое-то чувство свободы и спокойствия наполнило мою душу.
Мне хотелось остаться здесь навсегда, забыть про шумный свет и его суету.
Но нужно было ехать дальше.
Мы сели на лошадей и тронулись в путь.
К вечеру мы достигли перевала и остановились на ночлег.
Ночью в горах стало холодно, и я долго не мог уснуть.
Я думал о прошлом, о будущем, о своих надеждах и разочарованиях.
Звезды были необыкновенно яркими и близкими.
Казалось, до них можно было достать рукой.
На рассвете мы снова отправились в дорогу.
Спуск был крут и опасен, но мы благополучно добрались до долины.
Внизу нас встретила бурная река и зеленые виноградники.
Местные жители приняли нас радушно и предложили вина и сыру.
Я слушал их песни, смотрел на пляски и чувствовал себя счастливым.
Это путешествие оставило в моей памяти глубокий след.
Я часто вспоминаю эти дикие, величественные картины природы.
И теперь, в тишине моего кабинета, я вновь переживаю те мгновения.
Тишина горного утра была обманчива.
Солнце поднималось все выше, согревая промерзшие за ночь скалы.
Туман в ущельях начал медленно рассеиваться, открывая взору бездонные пропасти.
Птицы, парящие в вышине, казались крошечными точками на фоне синего неба.
Мы тронулись в путь по узкой тропе, петлявшей над обрывом.
Острые камни то и дело срывались из-под копыт наших лошадей.
Проводник наш, старый горец, шел впереди и указывал безопасную дорогу.
В полдень мы сделали привал у горного источника с ледяной водой.
Вода была настолько чиста, что дно ручья было видно на большой глубине.
После короткого отдыха мы продолжили наш тяжелый подъем на хребет.
К вечеру погода резко переменилась, подул холодный и пронзительный ветер.
Тяжелые тучи заволокли небо, и начался мелкий, надоедливый дождь.
Нам пришлось ускорить шаг, чтобы успеть добраться до пастушьего жилища.
Внутри было тепло и сухо, горел небольшой костер.
Хозяин предложил нам горячего чая с горными травами.
Мы долго сидели у огня, слушая вой ветра за стенами.
Разговоры смолкли, каждый думал о чем-то своем.
Я смотрел на огонь и чувствовал, как усталость медленно покидает мое тело.
Наконец, непогода стихла, и на небе показались первые звезды.
Я вышел на воздух и вдохнул свежий, очищенный дождем воздух."""
```

Рис.3 – Замена демонстративного текста на кастомный (Продолжение повести М.Ю. Лермонтова «Герои нашего времени»)

2. Запустите метод make_sentence() без дополнительных параметров. Если модель возвращает None, объясните в отчете, почему это происходит (справка: библиотека отклоняет фразы, которые слишком сильно дублируют оригинал или если в графе переходов возник тупик) и как параметр tries решает эту проблему.

```
[14]
0
сек.
Мы тронулись в путь по узкой тропе, петлявшей над обрывом.
Острые камни то и дело срывались из-под копыт наших лошадей.
Проводник наш, старый горец, шел впереди и указывал безопасную дорогу.
В полдень мы сделали привал у горного источника с ледяной водой.
Вода была настолько чиста, что дно ручья было видно на большой глубине.
После короткого отдыха мы продолжили наш тяжелый подъем на хребет.
К вечеру погода резко переменилась, подул холодный и пронзительный ветер.
Тяжелые тучи заволокли небо, и начался мелкий, надоедливый дождь.
Нам пришлось ускорить шаг, чтобы успеть добраться до пастушьего жилища.
Внутри было тепло и сухо, горел небольшой костер.
Хозяин предложил нам горячего чая с горными травами.
Мы долго сидели у огня, слушая вой ветра за стенами.
Разговоры смолкли, каждый думал о чем-то своем.
Я смотрел на огонь и чувствовал, как усталость медленно покидает мое тело.
Наконец, непогода стихла, и на небе показались первые звезды.
Я вышел на воздух и вдохнул свежий, очищенный дождем воздух."""

print("Размер кастомного корпуса:", len(corpus_custom), "символов.")

model_custom = markovify.Text(corpus_custom)

print("\n— ГЕНЕРАЦИЯ БЕЗ ПАРАМЕТРОВ tries —")
for i in range(5):
    sentence = model_custom.make_sentence()
    print(f"Фраза {i+1}: {sentence}")

print("\n— ГЕНЕРАЦИЯ С tries=500 —")
for i in range(5):
    sentence = model_custom.make_sentence(tries=500)
    print(f"Фраза {i+1}: {sentence}")
```

```
Размер кастомного корпуса: 2899 символов.

— ГЕНЕРАЦИЯ БЕЗ ПАРАМЕТРОВ tries —
Фраза 1: None
Фраза 2: None
Фраза 3: None
Фраза 4: None
Фраза 5: Я думал о чем-то своем.

— ГЕНЕРАЦИЯ С tries=500 —
Фраза 1: Я думал о чем-то своем.
Фраза 2: Я думал о чем-то своем.
Фраза 3: Я думал о чем-то своем.
Фраза 4: Я думал о чем-то своем.
Фраза 5: Я думал о чем-то своем.
```

Рис.4 – Генерация на кастомном корпусе (2906 символов) с параметрами по умолчанию и tries=500.

Результат:
1. Генерация без параметров : Модель выдала несколько значений None, и лишь один раз смогла сгенерировать фразу («Я думал о чем-то своем»). Это связано с тем, что при малом количестве попыток алгоритм часто попадает в тупики (нет пути к токену [END]) или выдает точные копии, которые библиотека отклоняет.
2. Генерация с tries=500: Увеличив количество попыток до 500 модель перестала выдавать None и стабильно генерирует фразу. Но все 5 раз она выдала одно и то же(«Я думал о чем-то своем»).

Объяснение:
Параметр tries=500 решает проблему с None, заставляя алгоритм делать больше попыток, чтобы найти подходящий путь в графе. Однако из-за того, что текст всё ещё недостаточно велик для state_size=2, этот подходящий путь в графе оказался всего один. Поэтому находя его, модель начинает зацикливаться и выводить одно и то же предложение.

Задание 3. Комбинирование стилей (Генеративный синтез)
1. Создайте два разных текстовых объекта: corpus_A (например, деловые новости) и corpus_B (например, сказки). Обучите на них две отдельные модели.

```
[15]
0
сек.
corpus_A = """Центральный банк принял решение сохранить ключевую ставку на прежнем уровне.
Инфляция в годовом выражении замедлилась до целевых значений.
Правительство утвердило пакет мер поддержки малого бизнеса.
Крупная компания объявила о планах выхода на международные рынки.
Аналитики прогнозируют рост инвестиций в технологический сектор.
Фондовый рынок отреагировал ростом на публикацию отчётности.
Совет директоров назначил нового генерального директора.
Сделка по слиянию двух банков получила одобрение регулятора.
Объём экспорта увеличился по сравнению с прошлым кварталом.
Минэкономразвития представило прогноз социально-экономического развития."""

corpus_B = """Через базарную площадь идет полицейский надзиратель Очумелов в новой шинели.
За ним шагает рыжий городовой с решетом, полным конфискованного крыжовника.
Вдруг слышится визг, и из склада выбегает собака, а за ней гонится человек.
Это золотых дел мастер Хрюкин, он бежит за собакой и кричит.
Собака кусает его за палец, и Очумелов приказывает истребить ее.
Но кто-то из толпы говорит, что это собака генерала Жигалова.
Очумелов сразу меняется в лице и начинает потеть.
Генеральская собака? Зачем же вы ее трогали?
Ты, Хрюкин, сам виноват, не суйся со своим пальцем.
Толпа смеется, а Очумелов продолжает ругать Хрюкина."""

model_A = markovify.Text(corpus_A, state_size=1)
model_B = markovify.Text(corpus_B, state_size=1)
```

Рис.5 – Созданы два разных текстовых объекта: corpus_A – деловые новости, corpus_B – отрывок из рассказа А.П. Чехова «Хамелеон». Две отдельные модели обучены на текстовых объектах.

2. Используйте встроенную функцию markovify.combine([model_A, model_B], [0.5, 0.5]) для слияния моделей с равными весами. Генерируйте текст и покажите в отчете примеры получившегося «смешанного» стиля.



```
[15]
0
сек.

corpus_A = """Центральный банк принял решение сохранить ключевую ставку на прежнем уровне.
Инфляция в годовом выражении замедлилась до целевых значений.
Правительство утвердило пакет мер поддержки малого бизнеса.
Крупная компания объявила о планах выхода на международные рынки.
Аналитики прогнозируют рост инвестиций в технологический сектор.
Фондовый рынок отреагировал ростом на публикацию отчётности.
Совет директоров назначил нового генерального директора.
Сделка по слиянию двух банков получила одобрение регулятора.
Объём экспорта увеличился по сравнению с прошлым кварталом.
Минэкономразвития представило прогноз социально-экономического развития."""

corpus_B = """Через базарную площадь идет полицейский надзиратель Очумелов в новой шинели.
За ним шагает рыжий городовой с решетом, полным конфискованного крыжовника.
Вдруг слышится визг, и из склада выбегает собака, а за ней гонится человек.
Это золотых дел мастер Хрюкин, он бежит за собакой и кричит.
Собака кусает его за палец, и Очумелов приказывает истребить ее.
Но кто-то из толпы говорит, что это собака генерала Жигалова.
Очумелов сразу меняется в лице и начинает потеть.
Генеральская собака? Зачем же вы ее трогали?
Ты, Хрюкин, сам виноват, не суйся со своим пальцем.
Толпа смеется, а Очумелов продолжает ругать Хрюкина."""

model_A = markovify.Text(corpus_A, state_size=1)
model_B = markovify.Text(corpus_B, state_size=1)

model_mixed = markovify.combine([model_A, model_B], [0.5, 0.5])

print("— СМЕШАННЫЙ СТИЛЬ (Новости + отрывок из рассказа) —")
for i in range(10):
    sentence = model_mixed.make_sentence(tries=200)
    print(f"Фраза {i+1}: {sentence}")

— СМЕШАННЫЙ СТИЛЬ (Новости + отрывок из рассказа) —
Фраза 1: Вдруг слышится визг, и начинает потеть.
Фраза 2: За ним шагает рыжий городовой с прошлым кварталом.
Фраза 3: Объём экспорта увеличился по сравнению с решетом, полным конфискованного крыжовника.
Фраза 4: Сделка по сравнению с решетом, полным конфискованного крыжовника.
Фраза 5: Очумелов сразу меняется в технологический сектор.
Фраза 6: Фондовый рынок отреагировал ростом на международные рынки.
Фраза 7: Сделка по сравнению с решетом, полным конфискованного крыжовника.
Фраза 8: Вдруг слышится визг, и кричит.
Фраза 9: Вдруг слышится визг, и кричит.
Фраза 10: Вдруг слышится визг, и начинает потеть.
```

Рис.6 – Результат смешения текста с равными весами командой markovify.combine([model_A, model_B], [0.5, 0.5]).

Результат:

При слиянии двух моделей через markovify.combine их словари объединились, и из-за того, что контекст ограничен всего одним словом, матрица вероятностей получилась достаточно плотной для поиска путей. Алгоритм легко находит переходы к токену [END], поэтому параметр tries=200 успешно справляется с задачей. Но из-за простоты модели и малого объема текстов возникают смысловые нестыковки: генератор часто смешивает стили в пределах одного, а также повторяет одни и те же удачные комбинации.

Ссылка на Google Colab:
https://colab.research.google.com/drive/1tp6E9tQEBCKeDaKkjBQ6h9t4nXeOFjjx
Ссылка на GitHub:
https://github.com/Enot2130/Sitnikov_1iis41/tree/main/Устройство%20и%20функционирование%20интеллектуальных%20информационных%20систем/Статистическая%20генерация%20текста%20на%20основе%20марковских%20цепей

Контрольные вопросы

1. Сформулируйте основное марковское свойство («отсутствие памяти») применительно к генерации текста.
Вероятность выбора следующего слова зависит только от текущего состояния (последних N слов) и не зависит от всей предыдущей истории текста.
2. Что такое N-грамма? Примеры униграммы, биграммы и триграммы для фразы «Весело жить в такой земле».
Последовательность из N элементов.
Униграмма: «Весело», «жить».
Биграмма: «Весело жить», «в такой».
Триграмма: «Весело жить в».
3. Как увеличение state_size влияет на объем памяти и связность фраз?
Объем памяти (матрица переходов) растет, связность фраз повышается, но текст сильнее сближается с оригиналом.
4. Почему марковские цепи не способны улавливать долгосрочный сюжетный контекст?
Из-за «отсутствия памяти» модель не видит слов дальше своего контекстного окна (N слов) и не помнит тему абзаца или сюжет.
5. Что означает None при вызове make_sentence() и как это предотвратить?
Это тупик в графе (нет пути к [END]) или отбраковка слишком точной копии оригинала. Решение: увеличить tries, уменьшить state_size или увеличить объем корпуса.
6. Зачем используются скрытые токены [START] и [END]?
[START] задает начальное состояние, а [END] останавливает генерацию, позволяя строить завершенные предложения.
7. Каким образом markovify.combine управляет стилистическим весом?
Принимает список моделей и веса (например, [0.8, 0.2]). Чем выше вес, тем чаще генератор выбирает переходы из этой модели.
8. Почему при state_size=1 бывают ошибки в окончаниях русских слов?
В русском языке род и падеж зависят от нескольких слов. Одного предыдущего слова недостаточно для правильного согласования.
9. В чем фундаментальное отличие статистического графа от LLM?
Марковская цепь – частотный граф переходов. LLM используют нейросети, эмбеддинги и внимание, понимают семантику и удерживают весь контекст.
10. Как объем и жанровое разнообразие корпуса влияют на матрицу переходов?

Чем больше объем, тем плотнее матрица (меньше None). Разнообразие жанров расширяет словарь, но на малых текстах делает граф разреженным.

Вывод

В данной лабораторной работе я изучил принципы статистической генерации текста на основе марковских цепей и освоил библиотеку markovify. На практике я обучил модели первого и второго порядка на классической прозе и оценил влияние параметра state_size на связность и оригинальность фраз. Также я проверил работу генератора на кастомном корпусе и убедился, что при малом объеме текста модель выдает None из-за разреженности графа и тупиков, а параметр tries лишь увеличивает число попыток, но не решает проблему нехватки данных. Кроме того, я освоил объединение моделей разных стилей через markovify.combine.